

Proyectos II, integración y preparación de datos

Memoria final

Esta plantilla es orientativa y se puede modificar.

Sea cual sea el orden de las secciones y contenidos, la memoria debe contestar a los siguientes puntos:

- Alcance: contexto del TFM, importancia y originalidad del estudio
- Fuentes de datos usadas
- Objetivos del proyecto.
- Resultados obtenidos por objetivo.
- Relevancia de los resultados en el plano social, científico o empresarial.
- Reflexión sobre la privacidad y legalidad de la adquisición de los datos y cómo ha limitado los objetivos del proyecto.
- Actualización de la entrega HITO 1 como anexo.

Autores

Nombres y apellidos de los autores:

Aitana	Alberola Camarasa
Bernat	Pertegaz Ruiz
Eva	Sánchez Cabrero
Sergio	Terol Torres

1. Alcance del proyecto

El estudio se centra en el análisis de los datos correspondientes a las últimas cuatro ediciones de las maratones de Murcia y Valencia, es decir, las de los años 2022, 2023, 2024 y 2025. Se trabajará con información individualizada de los corredores con el objetivo de realizar un análisis comparativo y evolutivo del rendimiento deportivo, además de ajustar un modelo predictivo que, con información de la velocidad en los primeros tramos de la carrera, sea capaz de predecir el tiempo final de un corredor.

El proyecto no se limitará solamente al ámbito deportivo, sino que también estudiará la influencia de un factor externo, la meteorología, en un evento multitudinario como la maratón de Valencia.

1.1. Objetivos del proyecto

- 1- Caracterización de la maratón y relación con variables meteorológicas.
- 2- Agrupar los corredores para encontrar perfiles y formas distintas de correr una maratón.
- 3- Análisis del ritmo de los corredores por tramos y predicción del tiempo final.
- 4- Comparar y caracterizar la Maratón de Murcia frente a la de Valencia en términos de participación y rendimiento, e identificar perfiles de ritmo entre sus corredores mediante clustering.

1.2. Utilidad del estudio

El estudio puede resultar de interés para distintos perfiles vinculados sobre todo al ámbito deportivo. Los corredores de la maratón podrían utilizar los resultados para optimizar la planificación futura del evento o mejorar su rendimiento individual. También puede resultar interesante para la organización de la carrera, para conocer las características de sus participantes y enfocar la asistencia o publicidad a ciertos grupos objetivo.

2. Configuración del proyecto

2.1. Fuentes de datos

Proyectos II, integración y preparación de datos

Para el estudio se han utilizado datasets de las maratones de Valencia y Murcia entre 2022 y 2025. Los datos deportivos se han obtenido de la Real Federación Española de Atletismo en formato PDF y posteriormente se han convertido a Excel con la ayuda de la herramienta 'I Love PDF'. Como la conversión generaba una hoja por cada página del PDF, se han unificado todas las hojas en un único documento con el formato necesario para el análisis con ChatGPT.

Estos datasets incluyen información de cada corredor, como posición, nombre, dorsal, país, club, licencia, categoría, posición dentro de la categoría, tiempo final, tiempo real, tiempos parciales por tramos, diferencias respecto a otros corredores y ritmo medio por kilómetro.

Además, se han incorporado datos meteorológicos de Meteostat para los días de carrera en Valencia y Murcia durante los mismos años. Estos archivos, descargados en formato Excel, contienen variables como temperatura, humedad, precipitación, viento y presión atmosférica. Con esta información se pueden analizar las condiciones climáticas de cada maratón y estudiar su posible relación con el rendimiento de los corredores.

2.2. Integración y transformación de los datos

Tras convertir los datos a formato xlsx e importarlos en R, se han realizado varias modificaciones para unificar los formatos. Primero se han leído todas las columnas como texto para evitar errores de importación. Después, se han transformado las columnas de tiempos de los corredores a un formato común HH:MM:SS, ya que cada base de datos presentaba formatos distintos.

También se han limpiado algunas variables, como Dif., eliminando el texto innecesario que aparecía antes del tiempo, y Prom., que se ha convertido a formato numérico para poder analizar el ritmo medio por kilómetro. En cuanto a los valores faltantes, la mayoría se encuentran en la variable Lic., que no resulta relevante para el análisis. Además, el valor faltante de Dif. en el primer corredor se ha sustituido por 0:00:00.

Finalmente, se han unido por filas las cuatro bases de datos de las maratones para trabajar con un único dataset. Las herramientas utilizadas para la conversión de variables son principalmente funciones del paquete 'dplyr', y hemos aprendido a utilizarlas en la asignatura de proyecto y en la de MDPI. Para la importación se ha utilizado la función Import Dataset de RStudio con la librería 'readxl'. En algunos casos se han usado expresiones regulares aprendidas en la asignatura de EDA.

3. Resultados obtenidos

3.1. Objetivo 1: Caracterización de la Maratón de Valencia y comparación con variables meteorológicas.



El objetivo 1 se ha centrado en caracterizar las ediciones de 2022, 2023, 2024 y 2025 de la Maratón de Valencia y en contrastar los resultados deportivos con las condiciones meteorológicas registradas durante la franja horaria de la carrera. El análisis se ha planteado como un estudio descriptivo: primero se han preparado e integrado los datos de corredores, después se han obtenido indicadores generales de participación y rendimiento, y finalmente se comparan estos indicadores con variables como temperatura, humedad, viento y precipitación.

Proyectos II, integración y preparación de datos



Partiendo de la limpieza explicada en el apartado anterior, en este objetivo ha sido necesario transformar las columnas de tiempo a un formato común hh:mm:ss o a segundos para poder calcular medias y ritmos. La columna de categoría se ha separado en sexo y categoría de edad. Además, en esta fase se han utilizado funciones de dplyr como mutate(), across(), filter(), group_by() y summarise(). También funciones de lubridate y hms para trabajar con tiempos. Para las salidas descriptivas se ha recurrido a resúmenes tipo summary/summarise y, para los gráficos se ha utilizado ggplot2.

El primer resultado relevante es el crecimiento de la participación. Se observa que la maratón pasa de 21.818 finalistas en 2022 a 30.760 en 2025, lo que supone un aumento de casi 9.000 corredores en cuatro ediciones, mostrando una consolidación de la prueba y buscando analizar si el perfil de participantes cambia con el paso de los años.

En cuanto al rendimiento global, el ritmo medio se mantiene bastante estable. Los valores obtenidos son 05:13 min/km en 2022, 05:12 min/km en 2023, 05:15 min/km en 2024 y 05:16 min/km en 2025. La diferencia entre años no es mucha, aunque se observa que 2023 es el año con mejor ritmo medio y 2025 el más lento. Esto puede estar relacionado con el aumento de participantes, con cambios en el perfil de corredores o con las condiciones ambientales de cada edición.




La distribución por categorías muestra que las más frecuentes son SENI, M40 y M45, con 21.984, 10.991 y 10.572 registros respectivamente. Este resultado indica que la prueba concentra una parte importante de corredores adultos. Además, se observa un aumento progresivo de la proporción de mujeres: del 19,2% en 2022 al 23,9% en 2025. Aun así, la participación masculina sigue siendo mayoritaria.



También se ha estudiado la nacionalidad y la pertenencia a club. España aparece siempre como el país con mayor número de corredores, seguida por nacionalidades europeas como Francia, Italia, Bélgica, Reino Unido o Países Bajos, lo que confirma

Proyectos II, integración y preparación de datos

el carácter internacional del evento. Respecto a los clubes, se observa que los corredores con club mantienen ritmos medios mejores que los independientes: 05:06 min/km frente a 05:26. Esto sugiere que la pertenencia a un club puede estar asociada a una mayor o mejor preparación.



Para estudiar el contexto climático se han utilizado ficheros meteorológicos horarios de cada edición. Se ha filtrado la franja de 8:00 a 15:00, que cubre la carrera, y se han calculado las medias correspondientes a cada variable. En ninguno de los cuatro años se registra precipitación, por lo que las diferencias más importantes se encuentran en la temperatura, humedad y viento.

Año	Temp. media	Humedad	Viento	Resumen
2022	12,6 °C	71,5%	3,92 km/h	Condiciones frescas y favorables
2023	12,2 °C	41,5%	11,35 km/h	Ambiente seco y buen rendimiento
2024	14,6 °C	80,4%	5,99 km/h	Año más húmedo
2025	18,7 °C	54,5%	16,6 km/h	Año más cálido y ventado

A partir de estos datos se ha realizado una comparación entre temperatura y rendimiento.

En primer lugar se han identificado los corredores que participaron en las cuatro ediciones, obteniendo 1.262 nombres. Dentro de ellos, 109 mejoraron su marca año tras año. Para evitar una comparación individual decidimos cambiar de estrategia y tomar la temperatura a las 8:00 y a las 15:00 y calcular la variación durante esas horas: 5,6 °C en 2022, 10,7 °C en 2023, 7,8 °C en 2024 y 10,0 °C en 2025.

El cruce entre meteorología y tiempos se ha realizado mediante `left_join()` entre la tabla de tiempos medios de aquellos que realizaron la carrera los 4 años y la tabla meteorológica. Después se ha calculado la correlación entre la variación de temperatura y el tiempo medio anual con `cor()`, obteniendo $r = -0,094$. Este valor es muy bajo, por lo que no se observa una relación lineal clara entre ambas variables.

2023 presenta la mayor variación de temperatura y, al mismo tiempo, el mejor tiempo medio; en cambio, 2025 también presenta una variación alta, pero registra el peor tiempo medio. Por tanto, la variación térmica por sí sola no explica el rendimiento. Parece más razonable considerar el conjunto de condiciones: temperatura inicial, calor final, humedad relativa, punto de rocío y viento. En este sentido, 2024 puede verse condicionado por la humedad elevada y 2025 por el calor y el viento.

3.2. Objetivo 2: Encontrar perfiles de corredores y formas distintas de correr una maratón


En este objetivo se utiliza la técnica de clustering en la Maratón de Valencia de 2025 para tratar de encontrar perfiles de corredores similares y diferentes formas de correr una maratón.

El clustering se va a hacer con los corredores que terminaron, agrupándolos en función de la velocidad que han llevado en cada tramo. Para ello se va a utilizar una medida de distancia de correlación (spearman). El objetivo es agrupar los corredores según la velocidad que llevan por tramos, para identificar grupos que hayan corrido esta maratón de forma similar.

La idea inicial era hacerlo con los corredores de todas las ediciones y usando como datos los segundos que tardaban en recorrer cada tramo, sin embargo, debido al tamaño del conjunto de datos, se tuvo que adaptar el objetivo. Tras muchos intentos y reflexiones, el clustering final se ha realizado sobre una muestra representativa de cada género de la Maratón de Valencia de 2025, con los datos convertidos a la diferencia de velocidad en m/s de cada tramo respecto al tramo anterior, para tener así todos los datos en una misma escala y que no haya necesidad de normalizar.

Para el grupo masculino, tras comparar los coeficientes de Silhouette de los distintos métodos de clustering, se ha escogido el clustering jerárquico con 4 grupos. Los grupos que más corredores contienen son los grupos 1 y 2.

Una vez agrupados los corredores masculinos, se ha sacado la media de cada variable de cada grupo y se han representado en este gráfico:




Como indica el gráfico, los cuatro grupos empiezan la carrera a un buen ritmo, pero a partir del kilómetro 20 empiezan a aparecer diferencias en el comportamiento de los grupos. El grupo 4 baja la velocidad en el tramo 15-20 y la sube en el siguiente tramo, 20-25. Tras este cambio reduce ligeramente la velocidad los siguientes dos tramos y termina la carrera con un último esfuerzo en el que sube el ritmo. El grupo 3 también tiene un tramo en el que sube la velocidad, y este es el tramo 30-35, el penúltimo, en el que aumenta la velocidad para después terminar la carrera reduciéndola ligeramente. Por último, los grupos 1 y 2 tienen un comportamiento parecido entre ellos, siendo la principal diferencia el tramo final, en el que el grupo 1 acelera y termina fuerte la carrera mientras que el grupo 2, acusando un poco más el cansancio, sigue reduciendo la velocidad.

En cuanto a rendimiento, se ha comparado el tiempo medio que ha tardado cada grupo en realizar la carrera, y los grupos más rápidos son el 2 y el 1, con unos tiempos de 3h 30min y 3h 33min, respectivamente. Tiene sentido que el 2 sea el que más rápido termina la carrera porque, pese a ir bajando la velocidad, lo hace de forma constante, y eso es una de las características de los corredores más profesionales. Los grupos 3 y 4, por otro lado, son los más lentos, ya que tardan de media 3h 48min y 3h 57min en completar la maratón.

En el grupo femenino se encontró un outlier no detectado previamente, que contenía valores imposibles en dos de los tramos de la maratón. Se tomó la decisión de quitarlo del análisis porque condicionaba los grupos formados. Sin esta observación, el método con mejor coeficiente de Silhouette fue el clustering jerárquico con 4 grupos, igual que en el masculino. De estos 4 grupos hay uno mayoritario, el 3, que contiene la mitad de las corredoras de la muestra.

Con los grupos ya hechos, la media de diferencia de velocidad por tramos queda de la siguiente manera:

Cambios de velocidad en cada grupo



El grupo que más llama la atención es el grupo 2, que es el que más baja el ritmo durante toda la carrera hasta el kilómetro 30, que empieza a acelerar y termina la carrera subiendo el ritmo. El grupo 1 es el único grupo que ya reduce su velocidad en los primeros tramos de la carrera, y pasada la media maratón lo suben. Esta subida parece pasarles factura y vuelven a bajar el ritmo en el penúltimo tramo, aunque en el último aceleran otra vez. Los grupos 3 y 4 llevan una tendencia parecida, bajando el ritmo ambos durante toda la carrera hasta el último tramo, que el grupo 3 sube el ritmo y el 4 lo baja un poco más. Esta diferencia en el tramo final puede ser clave en los resultados que veremos a continuación.

El tiempo medio que tarda cada grupo en finalizar la carrera es llamativo, ya que es el grupo mayoritario, el 3, el que mejor tiempo tiene, siendo este 3h 59min. Lo sigue de cerca el grupo 4, con 4h 4min, y esta diferencia de solo 5 minutos puede ser la ventaja que saca el grupo 3 en el tramo final. Los otros dos grupos, el 1 y el 2, terminan la maratón de media en 4h 15min y 4h 16min, por lo que no hay diferencia. Aun así, ambos grupos terminan con un último tramo más rápido que el anterior, lo que sugiere que han terminado con ganas.

En conclusión, tanto en masculino como en femenino, los grupos más rápidos son los que llevan una velocidad más estable a lo largo de la carrera, siendo los más inestables también los más lentos. Además, se ha visto que las distintas formas de correr una maratón pueden cambiar según el género, y que no hay una única forma correcta de hacerlo.

3.3. Objetivo 3: Análisis del ritmo de los corredores por tramos y predicción del tiempo final

Los tiempos parciales se convirtieron del formato HH:MM:SS a segundos para poder operar con ellos. Después, se calculó el ritmo de cada tramo (min/km) como la diferencia entre parciales consecutivos dividida entre los kilómetros del tramo.

Proyectos II, integración y preparación de datos

Finalmente, se filtraron los registros incompletos y los ritmos físicamente imposibles (menores de 2 o mayores de 20 min/km). El dataset final contiene corredores con los 10 parciales completos y válidos.

El primer resultado destacable es el patrón general de ritmo: los corredores tienden a salir ligeramente más rápido y a perder ritmo de forma progresiva a partir del kilómetro 30, siendo el tramo final (40–42,2 km) el más lento de media. Este patrón es consistente en todos los años analizados.




Gráfico 1. El gráfico de línea muestra cómo el ritmo medio (línea rosa) se mantiene relativamente estable hasta el tramo 7 (km 25–30) y cae de forma clara en los últimos tramos. La banda intercuartílica (P25–P75) refleja que el 50 % central de los corredores sigue exactamente el mismo patrón, descartando que sea un efecto de los valores extremos.

Al segmentar por grupo de rendimiento, se observa una diferencia cualitativa importante: los corredores más rápidos mantienen un ritmo casi plano a lo largo de toda la carrera, mientras que los más lentos presentan caídas mucho más pronunciadas en la segunda mitad. Esto sugiere que la gestión del esfuerzo es uno de los factores que más diferencia a los corredores populares de los de alto rendimiento.




Gráfico 2. Cada línea representa un grupo de rendimiento.

Respecto a la estrategia de carrera, la gran mayoría de los participantes presentó un positivo split (segunda mitad más lenta), y se encontró una correlación negativa entre el ritmo del primer tramo y la caída de ritmo al final: los corredores que salen más rápido llegan significativamente más lentos, lo que refuerza que una salida conservadora es más eficiente.




Gráfico 3. Más del 50 % de los corredores realizó un positivo split, frente a una 44.8% que mantuvo un ritmo constante o un 2.8% que aceleró en la segunda mitad.

Se entrenaron modelos de Regresión Lineal y Random Forest para cada sexo, donde el modelo Mk predice el tiempo final usando los ritmos de los primeros k tramos. El objetivo era evaluar con cuánta información parcial se puede predecir el resultado con suficiente precisión.




Gráfico 4. El RMSE cae rápidamente al añadir los primeros tramos y se estabiliza a partir del tramo 5-6, en ambos sexos. El Random Forest supera a la Regresión Lineal con pocos tramos, lo que indica que la relación entre el ritmo inicial y el tiempo final tiene componentes no lineales. Con todos los tramos disponibles (M10), ambos modelos alcanzan errores similares y pequeños. A menor valor, mejor predicción.




Gráfico 5. R² = 1 significa predicción perfecta. Con tan solo 4 tramos completados (los primeros 20 km), la regresión lineal ya explica más del 90% de la variación en el tiempo final, lo que demuestra que el ritmo de la primera mitad es un predictor muy potente del resultado final.

Los hombres son consistentemente más predecibles que las mujeres con pocos tramos, aunque la brecha desaparece a partir del tramo 6-7. Esto puede indicar que las mujeres tienen una estrategia de carrera más variable o menos predecible desde el inicio.

Proyectos II, integración y preparación de datos


La mejora más grande se produce en los primeros tramos: pasar de M1 a M2 ya sube el R^2 considerablemente, mientras que los últimos tramos (M8, M9, M10) apenas aportan mejora porque el modelo ya es casi perfecto.

Finalmente, se implementó una función `predecir_corredor()` que, dados los ritmos conocidos de un corredor (entre 1 y 10 tramos) y su sexo, devuelve el tiempo final estimado junto con su margen de error típico ($\pm$ MAE del modelo correspondiente).

3.4. Objetivo 4: Comparar y caracterizar la Maratón de Murcia frente a la de Valencia en términos de participación y rendimiento, e identificar perfiles de ritmo entre sus corredores mediante clustering

El objetivo 4 se ha centrado en caracterizar las ediciones de 2022, 2023, 2024 y 2025 de la Maratón de Murcia y compararla con la maratón de Valencia que ha sido caracterizada anteriormente en el objetivo 1, además, en este objetivo, se utiliza la técnica de clustering en la Maratón de Murcia en los años (2022-2025) para tratar de encontrar perfiles de corredores similares y diferentes formas de correr una maratón.

La parte comparativa analiza cuatro ediciones de la Maratón de Murcia (2022-2025) frente a las ediciones disponibles de Valencia, estudiando la evolución de la participación a lo largo de los años.




Para realizar este gráfico tuve que crear un factor de escala, ya que, al ser la diferencia de observaciones entre ambas maratones tan grande, he tenido que sacar el factor y multiplicar cada observación por el factor, para que sea comparable este gráfico. Además, he añadido dos ejes a cada lado siendo el derecho el de Murcia. (DIVIDO POR EL FACTOR PARA VOLVER A SU NÚMERO ORIGINAL).


Proyectos II, integración y preparación de datos

En ambos casos se aprecia una evolución positiva del número de inscritos, aunque con escalas muy diferentes, evidenciando la distinta dimensión y repercusión de ambas competiciones.

La distribución por género: Valencia ha logrado posicionarse mejor a nivel internacional atrayendo al público femenino. Murcia todavía tiene un margen de crecimiento muy grande para incentivar la participación de mujeres.




las nacionalidades más frecuentes: Murcia es una carrera de corte mayoritariamente nacional/regional. Valencia es un evento global y un imán de turismo deportivo masivo, atrayendo a miles de corredores extranjeros gracias a su fama.




Las categorías de edad predominantes: El perfil del corredor que compite en Murcia es más maduro, experimentado y veterano (M35-M50), mientras que Valencia atrae a una masa de corredores más jóvenes como podemos observar (SEN).

Proyectos II, integración y preparación de datos



El ritmo medio de los corredores y la proporción de atletas federados en club frente a los independientes.




Para la mayoría de estas gráficas en lo único que había que estar atento es en calcular el porcentaje dentro de su respectiva maratón, ya que si no, el resultado no sería correcto.

El objetivo de esta comparativa es entender en qué se parecen y en qué se diferencian ambas maratones como evento deportivo.

La parte de clustering se realiza sobre los corredores de la Maratón de Murcia que disponen de tiempos por tramo, agrupándolos en función de los segundos que tardan en recorrer cada segmento de 5 km, y calculando su velocidad media que lleva en dichos tramos, una vez hecho el cálculo, se seleccionan dichas variables para realizar el clustering. Para ello se utiliza la distancia de Spearman, que permite identificar corredores con una estrategia de carrera similar independientemente de su velocidad absoluta.

Tras comparar los métodos jerárquicos con Ward, el método de la media y K-medoides (PAM), se descarta el método de la media por producir clústers muy desequilibrados, y se selecciona Ward, con 3 clústers como la solución más informativa, respaldada por los coeficientes de Silhouette y las métricas de cIValid.

Tras hacerlo todo correctamente, este es el gráfico de perfiles de clústers:



En el eje X aparecen las variables Diff_1 a Diff_7, que representan el cambio de velocidad entre un tramo y el siguiente. Los valores del eje Y están estandarizados, por lo que valores positivos indican que, en promedio, la velocidad aumenta respecto al tramo anterior, mientras que valores negativos reflejan una disminución de la velocidad. El clúster que parece más favorable o eficiente sería el Clúster 1 (línea verde). La principal razón es que presenta una evolución progresiva de la velocidad a lo largo del recorrido. Aunque comienza con ligeras reducciones de ritmo en los primeros tramos, posteriormente aumenta de forma continua hasta alcanzar los valores más altos en los últimos segmentos (Diff_6 y Diff_7). Esto indica que los corredores de este grupo son capaces de mantener reservas y acelerar al final de la prueba, algo que suele asociarse con una mejor gestión del esfuerzo y una estrategia de carrera más eficiente.

3.5. Reflexión sobre privacidad y legalidad

Los datos utilizados corresponden a resultados oficiales publicados por la organización del Maratón de Valencia. El hecho de que estén disponibles únicamente en formato PDF, y no en formatos estructurados como CSV o Excel, no es casualidad puede ser una decisión deliberada de la organización que dificulta el tratamiento masivo de los datos y el análisis sobre ellos.

Podría interpretarse como una medida implícita de protección de los participantes, ya que desincentiva exactamente el tipo de análisis que nosotros hemos realizado. Para poder trabajar con ellos fue necesario convertirlos, lo que plantea que aunque los datos son técnicamente públicos, saltarse esa barrera de formato podría no estar alineado con la intención de la organización al publicarlos de esa manera.

Al incluir nombre, dorsal, sexo y categoría de edad, constituyen datos de carácter personal. En algunos objetivos del proyecto se ha trabajado con datos de corredores individuales identificables, lo que refuerza la necesidad de un uso responsable y no publicar estos datos fuera del contexto académico, no cruzarlos con otras fuentes y no utilizarlos con fines comerciales. En el análisis de este objetivo concreto las visualizaciones son siempre agregadas, sin identificar corredores individuales.

4. Lecciones aprendidas para mis futuros proyectos en Ciencia de Datos

Para futuros proyectos hemos aprendido que vale la pena empezar a dedicarle tiempo pronto, cuando la carga de trabajo de otras asignaturas es menor, en vez de hacer todo el trabajo durante las últimas semanas del cuatrimestre, en las que tenemos más carga académica.

Muchas veces se subestima la limpieza y preparación de los datos, y hemos aprendido que realmente es de las partes más laboriosas, incluso más que obtener los resultados.

Además, también hemos aprendido que es mejor dedicarle tiempo a hacer un buen análisis exploratorio para conocer bien los datos con los que se va a trabajar, porque después, al llevar a cabo los objetivos se entienden los resultados y los errores más fácil y rápidamente.


Este proyecto nos ha ayudado también a saber cómo lidiar con columnas con distintos nombres, formatos de tiempo inconsistentes y valores ausentes. Hemos reforzado el uso de `dplyr` y `ggplot2` para construir comparativas visuales significativas, aprendiendo a elegir el tipo de gráfico más adecuado según lo que se quería comunicar. Hemos comprendido que elegir una buena medida de distancia es tan importante como el propio algoritmo, y que la distancia de Spearman es la más adecuada cuando el objetivo es comparar perfiles en lugar de valores absolutos. También hemos aprendido a validar los resultados con varias métricas simultáneamente (`Silhouette`, `clValid`, `ARI`) y a no quedarnos con el primer resultado, sino a comparar métodos y justificar la elección.

ANEXOS

Objetivo 3:


Distribución del ritmo por tramo

Maratón de Valencia 2022–2025 — Eje Y invertido: arriba = más rápido



Perfil de ritmo por sexo


Eje Y invertido: valores más bajos = más rápido



Proyectos II, integración y preparación de datos



¿Los que salen más rápido (menor ritmo T1) pierden más ritmo al final?


Eje X: ritmo en T1 (min/km) — Eje Y: diferencia de ritmo T10-T1 (min/km)
Valores positivos en Y = se frenaron; negativos = aceleraron



Evolución del perfil de ritmo por año (2022-2025)


Eje Y invertido: arriba = más rápido





Proyectos II, integración y preparación de datos

Objetivo 1:



Proyectos II, integración y preparación de datos

